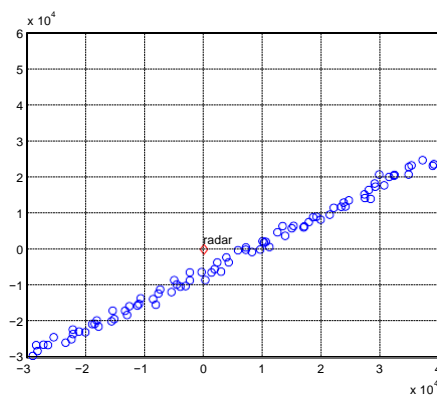


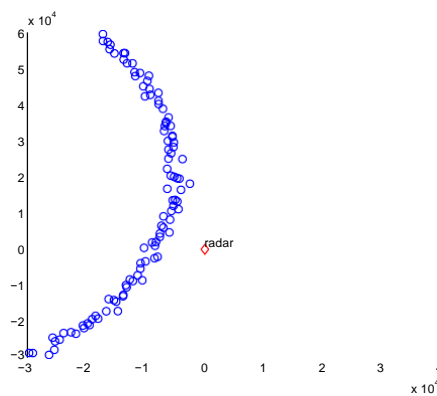
IA-856 Exercício Computacional Filtro de Kalman Giovani Chemello Caprio

O problema de rastreamento


Suponha que um dispositivo (como um radar) meça as duas posições coordenadas de objetos (avião, navio, etc) realizando movimentos dentro do alcance deste sensor. A Fig 1 apresenta três movimentos observados através de medidas sucessivas a cada 4s., tomando-se a posição do radar como referência.



(a) Movimento retilíneo



(b) Curva suave



(c) Manobra

Figura 1: Trajetórias observadas – escala em metros.

As trajetórias observadas não tem precisão suficiente para acompanhamento destes movimentos para, por exemplo, emitir alerta de colisões, detetar ataques em situação de guerra, etc. Além disso, é desejável estimar a velocidade do objeto móvel. Para este fim iremos utilizar um filtro de Kalman e adotaremos um modelo cinemático simples para a descrição dos movimentos. Identificam-se quatro variáveis de estados:

x_1 : posição do objeto na abcissa

x_2 : componente da velocidade do objeto na direção da abcissa

x_3 : posição do objeto na ordenada

x_4 : componente da velocidade do objeto na direção da abcissa

O modelo cinemático, conhecido como modelo de velocidade (quase) constante em cada uma das componentes ortogonais é descrito por:

$$\begin{bmatrix} x_i(k+1) \\ x_{i+1}(k+1) \end{bmatrix} = \begin{bmatrix} 1 & dT \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1(k) \\ x_2(k) \end{bmatrix} + \begin{bmatrix} 0 \\ \varepsilon_i(k) \end{bmatrix}$$

para $i = 1, 2$. Aqui temos que:

- $dT = 4s$ é a taxa de amostragem/intervalo de tempo entre as medidas;
- $\varepsilon_i(k)$ $i = 1$ ou $i = 2$ representa a alteração imposta à velocidade do móvel durante o intervalo de amostragem na direção coordenada correspondente. Como esta ação é desconhecida, deve-se modelar a aceleração imposta pelo navegador como uma amostra de ruído gaussiano a cada instante, com média nula e certa variância fixa, adotada *a priori*. Esta variância a princípio é desconhecida, e terá que ser estimada através de tentativas de ajustes do filtro de Kalman, variando-se este dado no modelo utilizado até se encontrar um valor representativo.

São disponíveis a cada instante medidas com ruído das posições cartesianas na forma seguinte:

$$\begin{aligned} z_1(k) &= x_1(k) + v_1(k) \\ z_2(k) &= x_2(k) + v_2(k), \quad k = 0, 1, \dots \end{aligned}$$

o número total de amostras k depende da permanência do objeto no alcance do sensor. Aqui $v_j(k), j = 1, 2$ representam os erros cometido pelo sensor, modelados por ruído gaussiano com média nula e variância conhecida, dada por $\sigma_{v_1}^2 = \sigma_{v_2}^2 = 1200^2$, sendo não-correlacionados.

As seqüências de dados de medidas para as três trajetórias estão disponíveis nos arquivos **reta.mat** e **curva_suave.mat** e **manobra.mat** (variável **x_m**), além dos dados exatos de posição dos objetos (variável **x_c**) disponíveis para efeito de comparação e avaliações de desempenho do filtro para cada trajetória.

Questões

1. Implemente o filtro de Kalman para estimar a posição no plano e a velocidade do móvel, assumindo-se que $\varepsilon(k)$ e $v(k)$ são processos estocásticos independentes brancos com média nula, com matriz de covariância $\Sigma_\varepsilon = \sigma_\varepsilon^2 I$ e $\Sigma_v = 1200^2 I$ sendo σ_ε^2 desconhecido.

Utilize os dados nos três arquivos e estabeleça condições iniciais apropriadas para o estado do filtro e para a covariância inicial, lembrando que ela deve ser suficientemente grande para representar o desconhecimento inicial que temos sobre a velocidade e o valor correto de posição.

Faça experimentos com as três trajetórias e verifique a adequação de ajustes do valor de σ_ε^2 para cada caso, através do erro que o filtro comente (vide os itens 2. e 4. em seguida, para adotar uma forma sistemática de avaliar o erro). Adote em seguida um único valor para σ_ε^2 que deverá ser mantido em todos experimentos subsequentes.

2. Estime o erro quadrático médio existente entre a posição real (coordenadas (\mathbf{x}, \mathbf{y})) e os valores estimados, a partir dos dados nos arquivos e o resultado do filtro. Verifique a compatibilidade dos erros observados com o erro médio quadrático de estimação de estados de posição teóricos do filtro, dados por elementos correspondentes da matriz de covariância do filtro de Kalman $P_x(k|k)$. Verifique a compatibilidade destes valores com a variância dos ruídos do sistema σ_e^2 e de observação σ_v^2 .
3. De forma similar, estime a covariância da saída (erro da medida, avaliada através da inovação) e compare com a covariância de erro de medida teórica do filtro de Kalman, dada pela matriz $P_z(k|k)$. Em seguida plote a verossimilhança das medidas ao longo do intervalo de observação através da distribuição condicional do erro de previsão da observação, dada por

$$p_{k|k-1}(z(k)|\hat{\mathbf{x}}(k|k-1), P_x(k|k-1)) = \frac{1}{|2\pi P_z(k|k-1)|} \exp - \frac{1}{2} (z(k) - z(k|k-1)) P_z(k|k-1)^{-1} (z(k) - z(k|k-1))'$$

Aqui, $z(k|k-1)$ é a previsão da medida para o instante k fornecida pelo filtro no passo anterior; $P_z(k|k-1)$ covariância da medida no instante k , prevista no instante anterior e $|\cdot|$ representa o determinante.

4. Analise a influência no comportamento do filtro na evolução do estado estimado, alterando os seguintes aspectos:
 - a inicialização do filtro,
 - as variâncias dos ruídos estado e da medida.

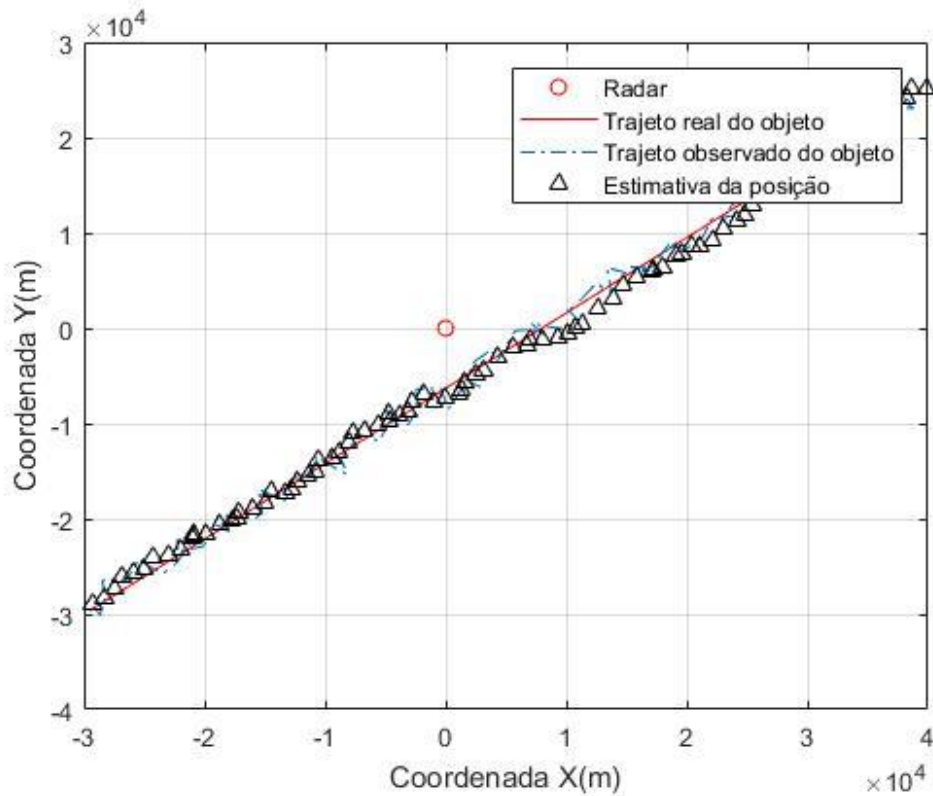
Comente os resultados. Sugestão: aumente e diminua a variância da ordem de uma grandeza.
5. Determine pela teoria se a estabilidade do filtro estacionário é garantida. Verifique pela implementação do filtro se ele atinge uma solução estacionária. Se positivo, verifique também
 - se a solução estacionária depende da condição inicial utilizada, a matriz $P_x(0)$.
 - se a solução encontrada de fato torna o filtro estacionário estável.

6. Verifique através do acompanhamento de erros se o filtro têm deficiências em curvas fechadas, e avalie a razão deste comportamento, explicando o observado.
7. Utilizando a informação sobre o erro previsto, proponha uma estratégia de adaptação do ganho do filtro de Kalman, para que ele rastreie melhor não estacionariedades do estado. Faça experimentos numéricos com a modificação proposta, e compare com a solução do item anterior.

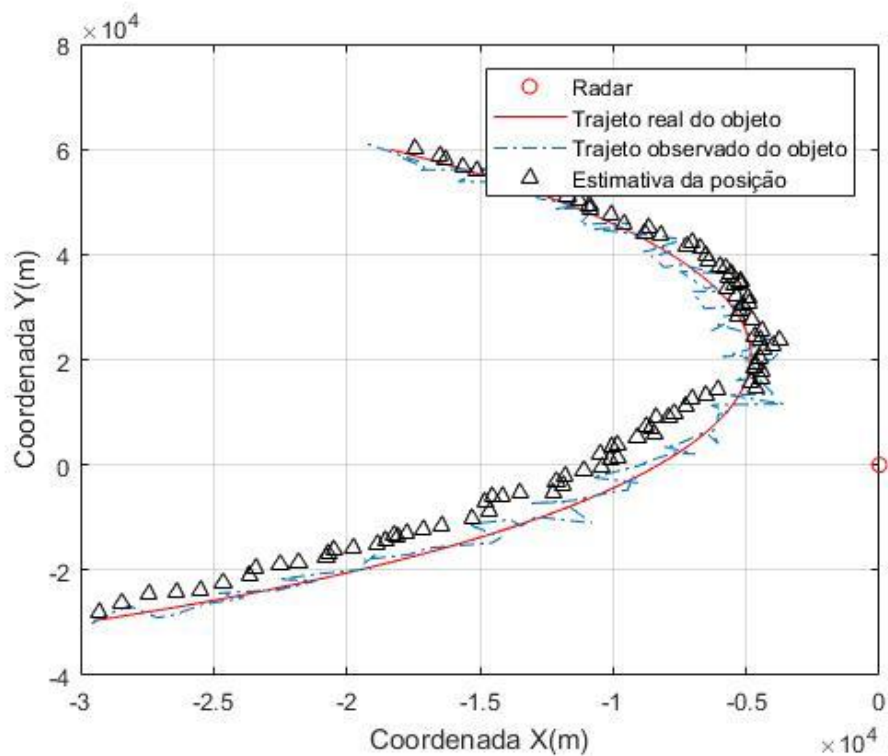
Experimento

Após a realização do experimento de implementação do filtro de Kalman, para as observações geradas pelo radar. Obtivemos o seguinte resultado:


- Reta



- Curva Suave



- Manobra



Claramente, se percebeu que a reta teve uma resposta satisfatória, a curva uma boa resposta e no caso da manobra uma resposta ruim.

Para obter a qualidade dessa aproximação da estimativa de uma forma numérica, foi calculado o erro quadrático médio entre a curva real e estimado. Além disso, obteus-se a velocidade média e sua variância para cada observação.

- Reta

| Erro Médio Quadrático | Velocidade Média | Variância(Velocidade) |
|-----------------------|------------------|-----------------------|
| 1.2115e+03 | 492.3853 | 5.8312e+03 |

- Curva Suave

| Erro Médio Quadrático | Velocidade Média | Variância(Velocidade) |
|-----------------------|------------------|-----------------------|
| 2.9443e+03 | 272.3832 | 1.9076e+04 |

- Manobra


| Erro Médio Quadrático | Velocidade Média | Variância(Velocidade) |
|-----------------------|------------------|-----------------------|
| 6.7030e+03 | 500.31 | 1.5182e+04 |

Portanto, percebe-se que o erro aumenta no caso de manobras brutas. Isto ocorre devido a matriz de covariância do erro(P) tentar acompanhar o estimado, mas não prever as mudanças bruscas.

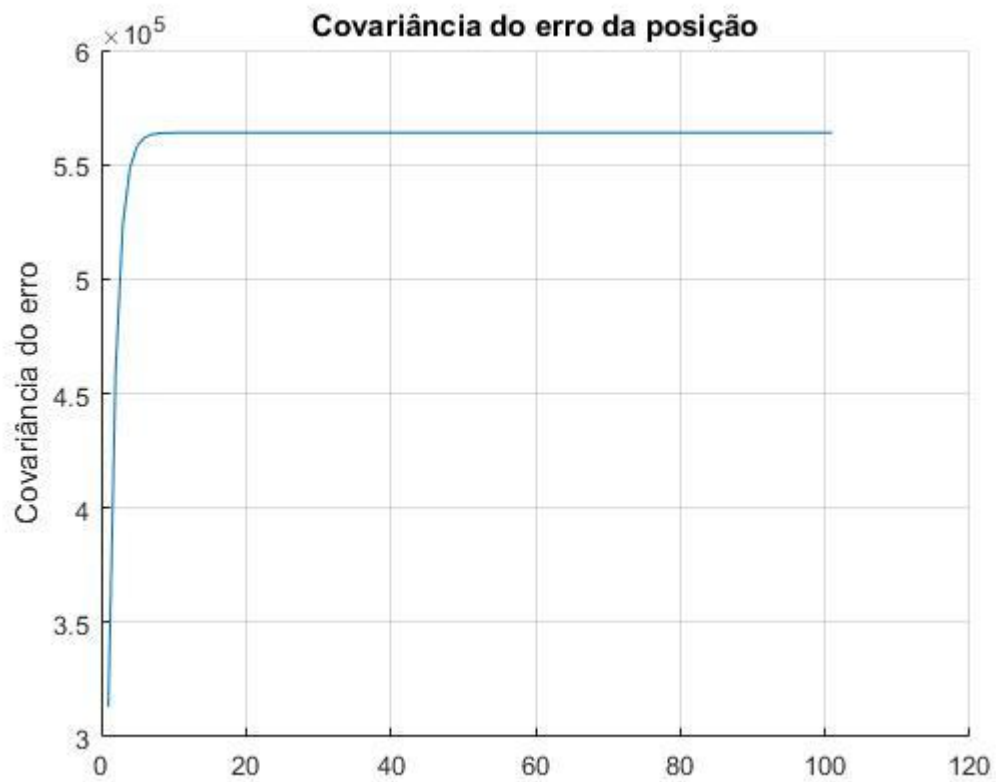
A fim de testes, foram mudados valores das matrizes Q e R, a variação de Q levou a estimação errada, devido ser do próprio sistema. Em mudanças de R, houve piora e melhora, menos significativas.

Por fim, foi feito o gráfico de Covariância de erros da posição, percebe-se que todos tenderam a um valor. Como pode-se ver a seguir:


- Reta



- Curva Suave



- Manobra



Código

```
close all, clear all, clc

load('reta.mat')
%load('curva_suave.mat')
%load('manobra')

posicao = x_m';

% Inicialização
media = 0; %média da distribuição gaussiana
variancia = 200;%variância da aceleração-estimado
sigma = sqrt(variancia);%desvio padrão
a_x = normrnd(media,sigma);%aceleracao em x com média nula
a_y = normrnd(media,sigma);%aceleracao em y com média nula
dT = 4; %Intervalo entre amostras
v_x = abs(posicao(1,1)-posicao(2,1))/dT;%velocidade em x
v_y = abs(posicao(1,2)-posicao(2,2))/dT;%velocidade em y
t = length(x_m(1,:)); %números de amostras de observação
cov_v=(1200).^2; %covariação
sigma_pos=sqrt(cov_v);%desvio padrão
R=[cov_v 0 0 0;0 variancia 0 0;0 0 cov_v 0;0 0 0 variancia];
%R=[variance_pos 0 0 0;0 variance 0 0;0 0 variance_pos 0;0 0 0
variance];
Q = [600^2 0 0 0;0 50^2 0 0;0 0 600^2 0;0 0 0 50^2]; %Erro da
velocidade)

% Planta
F = [1 dT 0 0; 0 1 0 0; 0 0 1 dT; 0 0 0 1];
G = [(1/2)*(dT)^2 0;dT 0; 0 (1/2)*(dT)^2; 0 dT];
H =[1 0 0 0; 0 1 0 0;0 0 1 0; 0 0 0 1];

figure(1)
plot(0,0,'or'); %Posicionamento do radar em coordenadas
legend('Radar')
xlabel('Coordenada X(m)'), ylabel('Coordenada Y(m)')
grid on
hold on

figure(1)
plot(x_c(:,1),x_c(:,2),'r') %traçado real(x_c)
legend('Radar','Trajeto real do objeto')

figure(1)
plot(x_m(1,:),x_m(2:,:),'-.') %traçado observado(x_m)
legend('Radar','Trajeto real do objeto','Trajeto observado do objeto')

% Variáveis Filtro de Kalman
vel=[];
Erro=0; %Erro que soma a cada iteração
errocov=[];
P = F*Q*F'; %Erro Inicial da Covariancia
D=diag(P);
P=diag(D); %zera os termos cruzados da matriz P
x = [-30000; v_x;-30000; v_y]; %estado inicial x=[x; x_dot; y; y_dot]
```



```

% Filtro de Kalman
for i = 1:t

    xkp = (F*x) + [0;a_x;0;a_y]; %z de kalman a cada iteraç o
    % B*[acel_x;acel_y]; % [0;acel_x;0;acel_y];

    %atualiza  o das acelera  es(modeladas como ru dos gaussianos)
    %para cada ciclo
    a_x = normrnd(media,sigma);
    a_y = normrnd(media,sigma);

    Mn = P*H' / (H*P*H'+R); %ganho

    %medi   es + respectivos ru dos do sensor
    Y =
F*[posicao(i,1);xkp(2,1);posicao(i,2);xkp(4,1)]; %+[normrnd(mean,sigma_pos)
;0;normrnd(mean,sigma_pos);0];
    %calculo do estado atual
    x = (xkp) + Mn*(Y - H*x);
    %atualizando a covari ncia do processo
    P = (eye(4) - Mn*H)*P; %atualiza  o covari ncia do erro
    errocov=[errocov; H*P*H']; %covari ncia do erro de estima  o do estado
    P = F*P*F' + Q;
    D=diag(P);
    P=diag(D); %zera os termos cruzados da matriz P

    %Somat rio para o EMQ
    Erro = Erro + sqrt((x(1,1)- x_c(i,1)).^2 + (x(3,1)- x_c(i,2)).^2 );
    %estimativa da velocidade
    vel=[vel; (sqrt((xkp(2,1)).^2 + (xkp(4,1)).^2))];

    figure(1)
    plot(x(1,1), x(3,1), '^k');
    legend('Radar','Trajeto real do objeto','Trajeto observado do objeto',
'Estimativa da posi   o')
end

%Erro M dio Quadr tico
Erro_MQ = Erro/t

% Velocidade M dia Estimada
V_media = sum(vel)/(max(size(vel)))

% Vari ncia da velocidade M dia
V_var = var(vel)

% Plotando a covari ncia do erro da posi   o
figure(3)
title('Covari ncia do erro da posi   o')
ylabel('Covari ncia do erro')
grid on
hold on
errocov_pos=[];
for i=1:4:(4*t)

    errocov_pos = [errocov_pos;errocov(i,1)];

end
figure(3)
plot(errocov_pos)

```